




# ESG新聞報導結構與 分類模型之文字探勘分析

社群媒體分析 第七組



謝青杉 M134610025

施文華 N134320017

吳悠綺 M134111038

許季盈 N134320018

蕭瑜珪 N124320023

劉彥伯 N134320031

劉宗泰 N134320011

- 
- 研 究 背 景
  - 方 法 流 程
  - 分 析 結 果
  - 模 型 比 較
  - 主 題 模 型
  - 結 論

# 臺灣 ESG 媒體報導之文字探勘分析

近年來，**ESG**（環境、社會、公司治理）已成為全球企業與政策制定者的**核心議題**。2024年，臺灣環境部啟動碳費徵收機制，金管會推動上市櫃公司依TCFD框架進行氣候財務揭露，加上COP29於同年11月召開，ESG相關政策討論在此期間達到年度高峰，使**2024年Q4成為觀察臺灣ESG輿論走向的關鍵時間窗口**，高度適合進行文字探勘分析。



## 研究期間

2024年9月1日 ~  
2024年12月31日

## 資料總量

4,459 篇新聞，  
ESG 相關佔 62.3%  
(約 2,776 篇)

**產經版** 對應「經濟」面向：

企業策略、綠色金融、供應鏈

**生活版** 對應「環境」面向：


氣候變遷、再生能源、碳中和

**全球版** 對應「政策」面向：

國際協議、碳費制度、揭露法規



# 工作流程





# 替換字串 => 中文斷詞 => 清除停用詞

## 參數設定:

artContent

## 替換字串設定:

\n>> ,

\n\n>>。

https?:://[^\s]+|www.[^\s]+>>

Sent from JPTT on my \w+>>

▲>>

臺灣>>台灣

▪ [^\n]\*>>

## 中文斷詞

選擇處理欄位:result

## 定義詞彙:

綠能 1000

再生能源 1000

## 清除停用字

最終清除總數:886,942筆



# DTM (文件詞矩陣) 建構結果

轉為DTM  (38)

參數設定

Input - 24

任務結果

201

字數



4325

文章數




- 將非結構化文本轉換為數值化的DTM (Document-Term Matrix)
- 每筆資料以詞彙出現頻率表示

本研究共：  
4,325 篇文章  
201 個詞彙特徵

將作為後續文本分類模型之輸入特徵

# 計算相關性矩陣詞彙關聯性分析 (CORRELATION MATRIX)

熱圖



- 計算詞與詞之間的相關性
- 數值越高代表兩詞越常同時出現
- 以熱圖方式呈現關聯強度
- 顏色越深代表關聯性越高


本研究觀察：

- 詞彙呈現群聚現象
- 顯示ESG議題中存在高度關聯的關鍵詞群



# 計算共現矩陣詞彙共現分析 (CO-OCCURRENCE MATRIX)

熱圖




- 計算詞與詞在同一篇文章中同時出現的次數
- 數值越高代表兩詞共同出現越頻繁
- 以熱圖呈現詞彙共現關係
- 顏色越深代表共現次數越高
- 

## 本研究觀察：

- 部分詞彙具有高共現頻率
- 顯示ESG議題中存在核心詞彙組合


# 單中心詞彙關聯網路圖 (SINGLE-CENTER NETWORK)



- 以特定主題詞（如ESG）為中心
- 篩選與其關聯性較高的詞彙
- 以網路圖呈現詞與詞之間的連結
- 節點代表詞彙，連線代表關聯關係
- 線條越粗代表關聯越強



# 整體詞彙關聯網路圖 (WORD NETWORK)



- 以所有關鍵詞為節點建立整體網路
- 節點大小代表詞彙重要性或出現頻率
- 連線代表詞與詞之間的關聯關係
- 線條越粗代表關聯越強

## 本研究觀察：

- 詞彙呈現群聚現象
- 部分詞彙形成核心節點
- 顯示ESG議題具有明顯結構性



# TF-IDF計算

- ▶ 本研究設定**最大特徵數量上限為 2,000 筆**，從聯合新聞關於 ESG / 碳市場看板當中，**萃取出 1,000 個關鍵詞彙**（含 system\_id）作為初始特徵矩陣。
- ▶ 資料來源主要為「**全球、生活、產經**」三個分類，以 artCategory 作為後續分類預測的目標標籤。
- ▶ 同時過濾「今天」「表示」等通用停用詞的干擾。



# 資料來源、欄位與參數篩選

## ▶ 看板來源：

聯合新聞：全球、生活、產經

## ▶ 搜尋日期起始：

2024/09/01 ~ 2024/12/31

## ▶ 關鍵字：

碳費、碳稅、碳排、碳權、ESG、永續、碳盤查、淨零、  
溫室氣體、碳中和、減碳、碳交易、永續發展、ESG報告、  
氣候變遷、碳排放權。

最終選取重要性分數前 186 個特徵作為模型輸入，大幅降低特徵維度同時保留關鍵資訊。


8


欄位數



4325

資料筆數





# TRAIN&TEST

- ▶ 總筆數：4,325 筆
- ▶ 訓練集(80%)：3,460 筆
- ▶ 測試集(20%)：865 筆

| 參數設定        | Input - 67 | 任務結果 |
|-------------|------------|------|
| 目標欄位 *      | 測試資料切割比率 * |      |
| artCatagory | 0.2        |      |
| 是否隨機排序資料    | 亂數種子       |      |
| 是           | 777        |      |
| 儲存更改        |            |      |





# LOGISTIC REGRESSION模型資訊


|                       |                       |                       |                       |
|-----------------------|-----------------------|-----------------------|-----------------------|
| 1.395<br>訓練時間         | 0.187<br>推論時間         | 0.896<br>測試資料準確度      | 0.896<br>測試資料micro-F1 |
| 0.638<br>測試資料macro-F1 | 0.891<br>測試資料加權F1     | 0.896<br>測試資料micro精確率 | 0.671<br>測試資料macro精確率 |
| 0.893<br>測試資料加權精確率    | 0.896<br>測試資料micro召回率 | 0.614<br>測試資料macro召回率 | 0.896<br>測試資料加權召回率    |

- ▶ **整體準確率達 89.6%**，加權 F1 達 0.891，模型在聯合新聞「全球」「產經」二類中表現優異。
- ▶ **macro-F1為0.638 低於 micro-F1為0.896**，顯示各分類間樣本數量分布不均，少數類別（如「生活」）的精確率相對較低。
- ▶ **訓練時間 1.395 秒、推論時間僅 0.187 秒**，對新聞即時分類具實用價值；建議可透過類別加權改善少數類別表現。




# LOGISTIC REGRESSION全球、生活、產經


分類：全球



分類：生活



分類：產經



# SVC

參數設定

Input - 66

任務結果

kernel

rbf

正規化參數 \*

1

Degree of polynomial kernel function ('poly')

3

隨機種子

9.156

訓練時間



3.24

推論時間



0.979

測試資料準確度



0.979

測試資料micro-F1



0.73

測試資料macro-F1



0.979

測試資料加權F1



0.979

測試資料micro精確率



0.739

測試資料macro精確率



0.979

測試資料加權精確率



0.979

測試資料micro召回率



0.723

測試資料macro召回率



0.979

測試資料加權召回率



1

懲罰係數



rbf

核函數



3

維度





► **本研究設定RBF**（徑向基函數）核函數，這是處理非線性問題的標準選擇。它可以把資料投影到更高維度，讓原本在低維度分不開的資料，在高維度變得可以分開。

► 為模型當中裡表現最好的，**準確率達到 97.9%，加權 F1 也是 0.979，但代價是訓練時間達 9.156 秒，推論時間達 3.24 秒，整體時間偏長。**

# LDA主題模型

## ESG 議題初步分群結果



將文本資料匯入 LDA 模型，  
根據詞彙共同出現關係進行主  
題分群

本研究設定：

- 主題數：3
- 迭代次數：2000
- 詞頻篩選：40 ~ 0.5
- alpha、beta：採用系統預設值

模型輸出：

- 主題關鍵詞
- 文件主題分布
- 主題占比

模型評估：

- Cv = 0.446（可接受）



# GUIDED LDA主題模型

60  
字數

0.469  
主題連貫性(Cv)

3  
主題數

1792.98  
混淆度

-1.019  
主題連貫性(UMass)

0.196  
主題連貫性(PMI)

Selected Topic: 3

Previous Topic

Next Topic

Clear Topic

Slide to adjust relevance metric (λ)


λ = 1

0.00.20.40.60.81.0

Intertopic Distance Map (via multidimensional scaling)



Top-30 Most Relevant Terms for Topic 3 (30.7% of tokens)



1.  $\text{salience}(\text{term } w) = \text{frequency}(w) * [\sum_t p(t | w) * \log(p(t | w) / p(t))]$  for topics  $t$ ; see Chuang et. al (2012)  
2.  $\text{relevance}(\text{term } w | \text{topic } t) = \lambda * p(w | t) + (1 - \lambda) * p(w | t) / p(w)$ ; see Stevart & Shirley (2014)

## GuidedLDA 為 LDA 延伸模型

- 差異：加入「種子詞」引導主題分群
- 本研究設定 ESG 相關種子詞，使主題分群

貼近 ESG 架構

環境：碳排、能源

社會：員工、供應鏈


治理：政策、法規

模型輸出：

主題關鍵詞

文件主題分布

可使主題更貼近 ESG 分析需求



# 總結分析

文字探勘分析 ESG 議題

GuidedLDA 在 主題連貫性 (UMass / PMI / Cv) 皆優於 LDA

顯示主題 更集中、語意更清楚

但在 Perplexity 上較高，代表 預測能力略下降

整體而言，GuidedLDA 提升可解釋性，但降低模型自由度

| 指標         | LDA     | GuidedLDA | 比較結果         |
|------------|---------|-----------|--------------|
| UMass      | -1.231  | -1.019    | ✓ 改善（更接近0）   |
| PMI        | 0.145   | 0.196     | ✓ 提升（關聯性更強）  |
| Cv         | 0.446   | 0.469     | ✓ 提升（語意更清楚）  |
| Perplexity | 1342.21 | 1792.98   | ✗ 變差（預測能力下降） |

顯示 GuidedLDA 更適合用於 ESG 議題之實務分析與決策支援



# THANKS

