

第二次讀書會專案報告

(日本二線城市討論度探討)

第八組

黃彥博 N134320019
陳昱璇 N134020002
黃足寧 N134320026
萬立庠 M126020020
吳瑤芯 B126060003
郭奕亨 N126020003



目錄

一、資料背景介紹與動機

二、Tarflow製作流程介紹


2.1、資料預處理


2.2、文辭和文件分析

W out 2.2、文件分類

2.3、主題模型


三、結論





資料背景介紹與動機





資料背景介紹與動機


現狀：


- 日本作為台灣旅客最熱門的境外旅遊目的地之一，相關討論在各大社群平台上持續累積。

研究材料：

- PTT Japan_Travel（日旅）版
 - 時間：2025/1/1~2026/4/26
 - 資料量：918筆
 - 既有旅遊研究多聚焦於東京、大阪等主流熱門城市，難以捕捉旅客對「非主流」目的地的偏好
- 

Tarflow製作流程介紹





2.1、資料預處理



2.1 資料_前處理



PTT 爬蟲 (8)

參數設定

選擇看板 *

homemaker(家官)

home_sale(房屋)

Hsinchu(新竹)

hypermall(賣場)

Insurance(保險)

iOS(iOS)

Japan_Travel(日旅)

搜尋關鍵字 ⓘ

日本旅遊

日本祕境

日本深度

日本鄉下

九州旅遊

排除關鍵字 ⓘ

東京

迪士尼

Disney

大阪

環球影城

搜尋起始日期

2025/01/01

搜尋結束日期

2026/04/26

儲存更改

替換字串 (11)

參數設定

Input - 8

選擇處理欄位 *

artContent

選擇替換規則檔案 ⓘ

-----請選擇-----

替換字串設定 ⓘ

\n\n>> °

\n>> ’

★\w+>>

/>>

([A-Za-z\s\,]+) >>

儲存更改

2.1 資料_中文斷詞_清除停用字

≡ 中文斷詞  (13)

參數設定

Input - 11

選擇處理欄位 *

result

定義詞彙 

九州 1000
東北 1000
四國 1000
由布院 1000
銀山溫泉 1000
...

選取字典 

-----請選擇-----

儲存更改

≡ 清除停用詞  (15)

參數設定

Input - 13

語言 *

Chinese

是否清除單字元 

是

清除數字 *

是

清除特殊標點符號 *

是

自定義停止詞

的
了
在
是
我

使用預設停止詞

是

是否轉為小寫英文

是

清除英文字母 *

否

清除換行符號 *


是

清除html tag *

是

儲存更改





2.2、 文辭與文件分析



轉為DTM



☰ 轉為DTM  (90)

參數設定

Input - 84

保留詞彙 ⓘ

以換行符號區隔，e.g.
國立中山大學
西子灣
壽山...

最多篩選詞彙數量 ⓘ

200

儲存更改

統計資訊

58

字數



841

文章數



任務結果

Show

10

 entries

system_id ↑	丸龜	仙台	倉敷	加賀	十和田湖	合掌村	嚴島	嚴美溪	四萬十川	奥入瀬	富山	小松	尾道	山寺	山形	岡山	岩手	平湯	廣島	弘前	徳島	新穂	東尋坊	松山	松山城	松島	松本	桂濱	樹冰	橘子	櫻桃	永平寺	瀬戸内海	牛舌	牡蠣	白川郷	白蝦	盛岡	睡魔		
1	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	7.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	
2	0.0	0.0	0.0	0.0	0.0	2.0	0.0	0.0	0.0	0.0	1.0	1.0	0.0	0.0	0.0	0.0	0.0	2.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
3	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
4	6.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	2.0	0.0	0.0	14.0	6.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	5.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
5	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	13.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
6	0.0	2.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
7	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0	0.0	0.0	1.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
8	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
9	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0
10	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	2.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0


Showing 1 to 10 of 841 entries



計算共現矩陣



熱圖




作法：

這些高共現的區塊可以幫助我們找出資料中的潛在關聯，例如哪些地點、產品、關鍵字或主題經常被一起提到。




字詞網路圖 (Shiny)



作法:

右側有一群字詞彼此連線密集，表示這些字詞在資料中經常共同出現，可能代表同一類型的主題或相近的地理、語意關係。





2.3、文件分類



2.2 tf-idf

統計資訊

58

字數



841

文章數



任務結果

Show 10 entries

Search:

system_id	丸龜	仙台	倉敷	加賀	十和田湖	合掌村	嚴島	嚴美溪	四萬十川	奥入瀬	富山	小松	尾道	山寺	山形	岡山	岩手	平湯	廣島	弘前
1	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.312700	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
2	0.000000	0.000000	0.000000	0.000000	0.000000	0.270890	0.000000	0.000000	0.000000	0.000000	0.118165	0.147735	0.000000	0.000000	0.000000	0.000000	0.000000	0.343504	0.000000	0.000000
3	0.000000	0.179117	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
4	0.192565	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.019944	0.000000	0.000000	0.000000	0.000000
5	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	1.000000	0.000000	0.000000	0.000000	0.000000

Show 10 entries


Search:

system_id	北陸	四國	東北
1	0.981905	0.000000	0.189374
4	0.000000	1.000000	0.000000
12	1.000000	0.000000	0.000000
17	0.000000	0.000000	1.000000
25	0.000000	0.000000	1.000000
27	1.000000	0.000000	0.000000

任務結果：

利用兩個不同保留重要字，分別去跑各自td-idf，看出各詞彙在文章中的代表性。

2.2 參數挑選



system_id	丸龜	仙台	倉敷	加賀	十和田湖	合掌村	嚴島	嚴美溪	四萬十川	奥入瀬	富山	小松	尾道	山寺	山形	岡山	岩手	平湯	廣島	弘前	德島	新穗
82	0.000000	0.000000	0.000000	0.069275	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.045328	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
93	0.000000	0.113954	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000
95	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.000000	0.691151	0.000000	0.000000	0.000000	0.495535	0.000000	0.000000	0.526076	0.000000	0.000000	0.000000

任務結果：

表格中的數值表示該字詞在該筆資料中的權重或出現程度。透過這種方式，原本的文字資料就可以被轉換成結構化資料，進一步進行計算與分析。



2.2.Train & Test



☰ Train&Test  (59)

參數設定

Input - 28

任務結果

目標欄位 *

region

▼

是否隨機排序資料

是

▼

測試資料切割比率 *



0.2

亂數種子

777

儲存更改

2.3 Logistic Regression



統計資訊

0.029

訓練時間



0.018

推論時間



0.98

測試資料準確度



0.98

測試資料micro-F1



0.981

測試資料macro-F1



0.979

測試資料加權F1



0.98

測試資料micro精確率



0.988

測試資料macro精確率



0.98

測試資料加權精確率



0.98

測試資料micro召回率



0.976

測試資料macro召回率



0.98


測試資料加權召回率




作法：

模型會根據前面挑選出的字詞特徵，判斷哪些字詞比較容易讓資料被歸類到這個分類中。

2.3 Decision tree





2.4 主題模型



GuidedLDA 參數設定

GuidedLDA 主題模型 (23)

參數有做更動，建議重新執行

參數設定

Input - 15

目標欄位 *

result

主題數 *

3

詞彙頻率下限 ⓘ

20

alpha

預設為主題數/50

主題種子字 ⓘ

仙台,青森,山形,藏王,東北,銀山溫泉
金澤,富山,名古屋,立山黑部,高山,合掌村
高松,岡山,廣島,瀨戶內海,嚴島神社,地方創生

迭代次數

300

主題保留關鍵字數量

20

詞彙頻率上限 ⓘ

0.7

Beta

預設為0.1

是否輸出字典 ⓘ

是

儲存更改

統計資訊

60

字數

3

主題數

-8.160

主題連貫性(UMass)

-6.513

主題連貫性(PMI)

0.513

主題連貫性(Cv)

13.12

混淆度

沒有使用到的主題種子字

東北, 名古屋, 嚴島神社,



作法：


透過保留重要字後進行主題模型，會讓主題更加接近自己的設定。



GuidedLDA-主題一



GuidedLDA Vis



作法:

1的主題模型呈現是"東北"



GuidedLDA-主題二



GuidedLDA Vis


Selected Topic: Previous Topic Next Topic Clear Topic

Slide to adjust relevance metric:⁽²⁾


$\lambda = 0.6$

0.0 0.2 0.4 0.6 0.8 1.0

Intertopic Distance Map (via multidimensional scaling)



Top-30 Most Relevant Terms for Topic 2 (34.3% of tokens)



Overall term frequency

Estimated term frequency within the selected topic

1. saliency(term w) = frequency(w) * [sum_t p(t | w) * log(p(t | w)/p(t))]; see Chuang et. al (2012)

2. relevance(term w | topic t) = λ * p(w | t) + (1 - λ) * p(w | t)/p(w); see Sievert & Shirley (2014)

作法:


2的主題模型呈現是"北路"



GuidedLDA-主題三



GuidedLDA Vis




作法：

3的主題模型呈現是"四國"

可以發現這些關鍵字紅色幾乎等於藍色，就表示這些關鍵字一出現就代表這個主題。






結論




成果總結

區域討論度趨勢圖


東北




北陸



四國



1. 整體趨勢均在 2025年10 ~ 12月出現轉折，2026一月數據三地皆無2025討論度高
2. 冬季：東北(35)
3. 春季：四國(40)
4. 夏季：四國(30)
5. 秋季：東北、四國(均在30左右)
6. 北陸整體趨勢相對平穩
7. 12月三地討論度都極低，推測是跨年月份大家可能相對想去熱門縣市、或年底比較忙等等



THANK YOU
Q&A

