

那些女孩難過的事

第11組

N124320015 林佩蓉
N134320027 邱展業
N134320003 顏暖真
N134320020 葉倩玟
N134320025 劉芝芸
N134320022 翁瑞琳
N134320032 黃靜儀



大綱



WEEK 6：文辭與文件分析

WEEK 7：文件分類模型

WEEK 9：主題模型探索

資料集介紹

資料來源

社群平台 以 PTT (WomenTalk) 為主要資料搜集來源，確保文本具備真實生活情境。

關鍵字設定

社群平台 以 PTT (WomenTalk) 為主要資料搜集來源，確保文本具備真實生活情境。

時間範圍

時間跨度 2021–2025 年，共 7,571 篇文章。
確保分析貼合現今社會氛圍與時代背景。

前處理：讀取、清理、斷詞與 **TF-IDF**



WEEK 6




WEEK 6：文辭與文件分析

WEEK 7：文件分類模型


WEEK 9：主題模型探索

文辭與文件分析_BIGRAM & TRIGRAM

Bigram Top 20



Trigram Top 20




BIGRAM視覺化

118 個節點，78 條邊

節點 = 詞，大小 = 出現頻率
邊 = 相鄰共現，粗細 = 共現次數

觀察到幾個明顯的詞群聚落：
感情詞群、職場詞群、家庭詞群
橋樑節點連接不同話題


Bigram 共現網絡圖 (Top 80 Bigrams)



PAIRWISE CORRELATION (詞彙共現相關性)

高度共現 (正相關)
傾向在同篇文章一起出現

- 女生 - 男生 (0.4043)
- 媽媽 - 爸爸 (0.3441)
- 小孩 - 父母 (0.2336)



高度互斥 (負相關)
極少在同篇文章出現，
代表截然不同的話題群

- 同事 - 新聞 (-0.0425)
- 台灣 - 同事 (-0.0447)

COSINE SIMILARITY (文件相似度)

Cosine Similarity 衡量
標籤文章用詞的相似度

- 「閒聊」與「難過」的相似度高達 0.8552
- 「閒聊」與「心情」的相似度達 0.8312

抽樣 500 篇文件間 Cosine Similarity 統計：


平均值：0.0115

中位數：0.0000

標準差：0.0236

最大值：0.5889

最小值：0.0000



WEEK 7



WEEK 6：文辭與文件分析

WEEK 7：文件分類模型


WEEK 9：主題模型探索

四種分類器表現比較


單次 7:3 切分可能因為隨機分割而產生偏差。

5-fold CV 把資料分成 5 份，輪流用 4 份訓練、1 份測試，取 5 次的平均分數，更能反映模型的穩定性。

測試集比較



模型穩定度 (5-fold CV)



使用 TF-IDF 特徵搭配集成模型（如 Random Forest），能有效提升文本分類的準確度與穩定性

四種模型的 CONFUSION MATRIX

對角線上的數字越大越好，代表正確分類的數量。
非對角線的數字代表錯誤分類（例如把「心情」誤判為「難過」）。

Logistic Regression

LR

實際標籤	問題	5	9	0	4	11	17
	心情	4	42	1	4	18	40
	新聞	0	0	29	2	1	5
	討論	4	9	1	5	11	19
	閒聊	7	25	3	8	29	77
	難過	31	112	4	35	140	1538
	預測標籤						

隨機森林

RF

實際類別	問題	0	0	0	0	0	46
	心情	0	0	0	0	0	109
	新聞	0	0	17	0	0	20
	討論	0	0	0	0	0	49
	閒聊	0	0	0	0	2	147
	難過	0	0	0	0	0	1860
	預測標籤						

四種模型的 CONFUSION MATRIX

對角線上的數字越大越好，代表正確分類的數量。
非對角線的數字代表錯誤分類（例如把「心情」誤判為「難過」）。

SVC

		SVC					
實際標籤	問題	1	5	0	4	3	33
	心情	3	22	1	3	10	70
	新聞	0	1	22	2	1	11
	討論	2	8	1	4	5	29
	閒聊	4	10	2	2	20	111
	難過	7	60	2	8	60	1723
		問題	心情	新聞	討論	閒聊	難過
		預測標籤					

決策樹







		DT					
實際標籤	問題	3	2	1	1	8	31
	心情	1	21	1	7	20	59
	新聞	0	2	29	0	3	3
	討論	3	6	0	4	11	25
	閒聊	3	13	1	8	25	99
	難過	54	80	2	86	171	1467
		問題	心情	新聞	討論	閒聊	難過
		預測標籤					

視覺化： 各類別邏輯回歸

這些詞是分類器用來區分
各標籤的關鍵線索。


例如：

若「分手」在「難過」類的
係數最高，代表出現「
分手」會強烈暗示這篇文
章標籤是「難過」。



泛化測試：跨時間穩定性

訓練集 2021–2023 (6,278 篇) → 測試集 2024–2025 (1,219 篇)



關鍵發現


差異均在 1–3% 以內
用詞特徵跨年份穩定

RF 仍然最佳 (80.4%)
即使跨時間仍領先其他模型

主要限制
少數類 (閒聊、心情、討論)
容易被誤判為「難過」
因為資料高度不均衡 (82%)

泛化測試

監督式分類器 (LR / RF / SVC / DT)
TF-IDF 特徵
7:3 資料切分 + 5-fold CV
Confusion Matrix + 迴歸係數
泛化測試 (跨領域/平台/時間)



RF 準確率微降至 0.804，與隨機切分極為接近。
證明「女孩們的用詞特徵跨年非常穩定」，無明顯時間漂移。

跨時間切分：

訓練集 (2021–2023) : 6278 篇
測試集 (2024–2025) : 1219 篇

: # 2-9b 泛化測試：四種模型在跨時間切分上的表現

```
print("泛化測試結果 (跨時間切分) : \n")
print(f"{'模型':<30s} {'隨機切分 Acc':>14s} {'跨時間 Acc':>14s} {'差異':>10s}")
print("-" * 70)

generalization_results = {}
for name, model_info in models.items():
    model_fresh = model_info.__class__(**model_info.get_params())
    model_fresh.fit(X_train_time, y_train_time)
    y_pred_time = model_fresh.predict(X_test_time)
    acc_time = accuracy_score(y_test_time, y_pred_time)
    acc_random = results[name]["accuracy"]
    diff = acc_time - acc_random
    generalization_results[name] = {
        "acc_random": acc_random,
        "acc_time": acc_time,
        "y_pred": y_pred_time,
    }
print(f"{'name':<30s} {'acc_random':>14.4f} {'acc_time':>14.4f} {'diff':>+10.4f}")
```

泛化測試結果 (跨時間切分)：

模型	隨機切分 Acc	跨時間 Acc	差異
LR (Logistic Regression)	0.7324	0.7268	-0.0056
RF (Random Forest)	0.8351	0.8039	-0.0312
SVC (Linear SVC)	0.7964	0.7711	-0.0253
DT (Decision Tree)	0.6884	0.7153	+0.0269

WEEK 9





WEEK 6：文辭與文件分析

WEEK 7：文件分類模型

WEEK 9：主題模型探索

最佳主題數 $K = 7$

根據 Perplexity & C_NPMI Coherence 評估最佳主題數



主題數並非越多越好，過度切分會導致語意品質下降

LDA視覺化：女孩們的七大難過主題 - 上


主題 0：朋友同事都好累，人際關係好崩潰)

關鍵字：朋友、結果、是不是、發現、喜歡



主題 1：身體不適真的累，看醫生也好崩潰

關鍵字：醫生、結果、上班、啊啊啊、晚上




主題 2：上班薪水都很累，人生現實好崩潰

關鍵字：工作、公司、同事、上班、薪水



主題 3：日常小事一直堆，情緒突然就破碎

關鍵字：老師、可是、時間、回家、起來



LDA視覺化：女孩們的七大難過主題 - 下

主題 4：新聞社會看了累，公共議題好無力

關鍵字：台灣、新聞、社會、這些、不要



主題 5：戀愛分手都會累，感情世界好破碎

關鍵字：男女、女友、一起、朋友、結婚




主題 6：家人期待一直追，情緒內耗好疲憊


關鍵字：媽媽、小孩、工作、不要、爸爸




LDA視覺化：文章的主題分布



難過的輪廓 標籤分布



小結



在 PPT 看似混亂的文字海中，自然語言處理技術不僅是數學運算，更是一種「數位同理心」
它精準地映射出女孩們最真實的壓力輪廓與生活痛點

那些女孩難過的事

她們難過的，不只是愛情

在 7,564 篇貼文中，我們發現最讓女孩崩潰的是「人際關係」——朋友的疏離、同事的摩擦、那些說不出口的委屈。

第二名是「身體健康」，生病看診的焦慮與無助；
第三名是「職場壓力」，薪水、主管、永遠加不完的班。

而刻板印象中的「感情問題」，其實只排第六。

這些女孩用文字留下的，是一整個世代的日常焦慮圖譜。
難過的不是單一事件，而是生活中每一個讓人喘不過氣的瞬間。