

第二次讀書會報告

第十二組

林永森 N124320002

盧鳳珠 N134320006

林姪婷 N134020008

陳 葳 N134320010

黃羽彤 N144020013

李玟娟 M145040001





Agenda

專案背景與說明

資料概況

資料分析

專案背景與說明

動機

自「新青安」貸款政策推行以來，房地產市場熱度與爭議並行。而房地產市場與金融市場高度連動，相關議題不僅集中於特定社群，也經常跨社群擴散。例如 PTT 房板主要聚焦於購屋、政策與房價，而股板則常從投資、資金流動與市場預期的角度切入。即使討論相同議題，不同社群之間仍可能呈現出差異化的語言使用方式與表達風格（如語氣、用詞習慣與關注重點）。在大量社群文本持續產生的情境下，若能自動辨識文本所屬的討論脈絡（如房市導向或投資導向），將有助於後續的資訊整理、主題分析與輿情觀察。因此，建立一個可有效區分不同社群語境的文本分類模型，具有實務上的基礎價值。

目的

1. 建立基礎社群文本分類模型：透過文本前處理、特徵轉換（TF-IDF）與傳統機器學習模型，實現對不同社群語境（房市 vs 投資）的自動分類，作為後續應用（如內容分流、主題分析）的前置模組。
2. 分析不同社群語言特徵差異：探討房板與股板在討論相似議題時，是否存在可被模型捕捉的詞彙、語意與語言風格差異（如語氣與用詞習慣），進一步理解分類結果的可解釋性。
3. 評估輕量模型在中文短文本上的效果：驗證在中文論壇短文本情境下，「規則化前處理 + TF-IDF + 線性模型」是否能在成本與效能之間取得平衡，作為實務應用中的高效率解法。
4. 比較不同模型對語義重疊問題的處理能力：在房市與投資議題高度交疊的情境下，比較不同模型（如 LR、RF、SVC、CNB、LSA）在分類表現上的差異，分析其對語義模糊邊界的處理能力。

N-gram 萃取與文字雲

房板 (home_sale) 雙詞組文字雲



股板 (Stock) 雙詞組文字雲



- 房板雙詞常見「信用管制、地板利率、貸款成數、房地合一」；股板常見「經濟火車頭、時空背景不同、政府炒房」，顯示兩板在主題關注上存在明顯差異。
- 兩板皆出現「不是這樣」等跨社群流行語，反映特定時期的共通語言風格。此類詞彙雖不具明顯主題區分力，但其在不同類別中的實際分布差異，仍可能被模型利用，顯示語意重疊與語言風格訊號同時存在。

N-gram 萃取與文字雲

房板 (home_sale) 三詞組文字雲




股板 (Stock) 三詞組文字雲



- 部分三詞組（如「房地產 經濟 火車頭」、「政府 帶頭 炒房」）具有較明確的語意指向，能反映特定社群的討論框架，具備潛在的分類價值。而如「不是 不是 這樣」等語氣或迷因用語，顯示語言風格在不同社群間具有一定程度的共享。
- Trigram 雖提供較強的語意資訊，但其出現頻率較低、特徵較為稀疏，覆蓋率有限，因此較適合作為輔助觀察工具，而非主要特徵來源。此結果亦與後續模型實驗一致：trigram 對部分模型（如 ComplementNB）可能有幫助，但對需要穩定特徵分布的模型（如 Logistic Regression）則未必帶來效能提升。

TF-IDF



模型成效比較

Model	Accuracy	Stock Precision	Stock Recall	Stock F1
Logistic Regression	0.73	0.47	0.70	0.56
Random Forest	0.65	0.38	0.69	0.49
Linear SVC	0.71	0.44	0.67	0.53
ComplementNB	0.74	0.48	0.67	0.56
LSA + SVC	0.70	0.44	0.73	0.55



結果

評估指標	目標值	LR (最佳參數)	CNB (最佳參數)
Accuracy	≥ 0.70	0.80	0.76
Stock Precision	≥ 0.55	0.62	0.51
Stock Recall	≥ 0.50	0.52	0.57
Stock F1-score	≥ 0.55	0.57	0.54

小結

- 本研究顯示，在不平衡且語意重疊的文本分類任務中，模型表現不僅取決於演算法本身，也高度依賴特徵工程與語料特性。相較於單純提升模型複雜度，理解特徵在不同模型中的作用更為關鍵。
- 本研究資料來自同一論壇下的不同板塊，語料同時包含共通語言與板塊特有用語。即使為跨板共用詞彙，其在不同板塊中的出現分布差異，仍可成為有效的分類訊號，使模型同時學習主題內容與語言風格。
- 此結果說明，語氣詞等「弱語意特徵」不應僅依直覺移除，而應依其在不同類別中的統計分布與模型特性進行判斷。
- 然而，由於模型部分依賴社群特有語言風格進行分類，當資料來源或語境改變時，相關特徵可能失效，進而影響模型的泛化能力。因此，本研究結果主要適用於相同語域（domain）下的分類任務。

主題模型



各主題命名與關鍵字的詮釋

聚落A:宏觀金融管制與

主題1: 房市政策 央行打房與金融風險

此主題屬於嚴肅的金融政策面。高度聚焦於「央行」與「銀行」的放款態度，探討「利率」變動、貸款「條件」限縮，以及政府打擊「炒房」所衍生的風險。

主題2: 新青安政策與建商動態

與主題1緊密相連，但更具體地鎖定在當前最具爭議地「新青安」政策。討論該政策如何影響年輕人進場，以及投資課與建商在政策下的應對與獲利。

聚落A:圍觀購屋與鄉民情緒 聚落C:跨市場資金流動與比較

主題3: 個人財務與家庭剛需

與主題5高度相關，但更偏向實務的財務盤點。網民在此討論誤了小孩產生的剛性買房需求，並互相比較「收入」、「資產」、「利息」負擔

主題5: 購屋焦慮與居住正義

此主題充滿強烈的個人情緒與鄉民文化。討論圍繞著高房價下的無奈，以及對高房價的解方

主題4: 股房市場連動與投資比較

圖表最左側被孤立的泡泡，捕捉到資料集橫跨「股版」與「房版」的特性。鄉民在此跳脫單純的買房實務，比較「台灣」整理的「股市/股票」與「房地產」的投資優劣，並劃分「自住」與「投資」的不同視角。

結論

透過本次LDA主題模型與DTM矩陣的分析，我們可以清晰地將PTT鄉民對房地產與經濟的討論，拆解為三個層次分明的維度

政策與制度層面(聚落A)

聚焦新青安貸款、央行利率與政府打房措施

情緒與生活層面(聚落B)

聚焦於貸款壓力、養育小孩與鄉民之間的相互調侃

投資與市場層面(聚落C)

聚焦於資金在股市與房市之間的流動與配置

THANK YOU
FOR YOUR TIME

