

ESG新聞報導結構與主題分類模型分析

社群媒體分析 第七組

謝青杉 M134610025

施文華 N134320017

吳悠綺 M134111038

許季盈 N134320018


蕭瑜珪 N124320023

劉彥伯 N134320031

劉宗泰 N134320011



工作流程



研究背景：從「詞頻」走向「語意」



上次回顧 (TF-IDF)

- 特徵工程：採用詞袋模型 (**BAG OF WORDS**)。
- 優勢：準確率極高 (**97.9%**)。
- 痛點：僅計算詞頻，無法捕捉上下文與深層語意關係。




本次進階 (TRANSFORMER)

- 技術核心：引入 **768** 維度 **BERT EMBEDDINGS**
- 核心問題：在無空格的中文結構下，是否仍需傳統「斷詞」前處理？
- 展望：實現從「算字數」到「懂語意」的轉換。

路徑 **A**：原始文字直接輸入(不斷詞)

直球對決：原生 **TOKENIZER**

- 核心概念：依賴 **BERT** 內建
- **WORDPIECE TOKENIZER** 自動處理。
- 流程簡化：跳過繁瑣的「中文斷詞」與「停用詞清洗」步驟。
- 優勢預期：保留句子最原始的語境與結構，展現模型原生處理能力。
- 實作：**CSV** 匯入 → **TRANSFORMERS EMBS** → 分類模型。



路徑 B：精細化前處理與綜合對照

比較指標	路徑 A (不斷詞)	路徑 B (斷詞 + ESG 詞庫)
前處理步驟	無 (直接輸入)	TARFLOW 斷詞 + 清除 88.6 萬筆停用詞
專業辨識力	一般通用語意	強化 ESG 、 GRI 等自定義專業術語
語意捕捉	完整上下文脈絡	精準切分特定實體 (ENTITIES)
運算 CP 值	高 (省時省力)	中 (前處理耗時，但專業度高)



精細斷
詞



88萬停用詞



ESG 專門詞庫



雙線並行測
試

WORD2VEC 模型說明 — SKIP-GRAM 架構

Skip-gram 三層神經網路架構



核心概念

- **WORD2VEC** 將每個詞訓練成一個 **100** 維的稠密向量，讓語意相近的詞在向量空間中也相近。
- **SKIP-GRAM** 訓練目標：給定中心詞 W_t ，預測其視窗範圍內的上下文詞 $W_{t-5}, \dots, W_{t+5}$ 。

為何選 **SKIP-GRAM**

- **ESG** 專業詞彙偏低頻如「碳盤查」「淨零」「範疇三排放」等 **ESG** 術語在新聞中出現次數有限。
- **SKIP-GRAM** 對低頻詞表現較好每個中心詞會產生 **2*WINDOW** 筆訓練對，低頻詞累積到足夠梯度。
- 對小語料較穩健本研究 **4,325** 篇新聞屬小語料，**SKIP-GRAM** 訓練雖較慢但泛化較佳。

WORD2VEC 參數設定與訓練結果

☰ Word2Vec (144) 參數有做更動，建議重新執行

參數設定

Input - 136

任務結果

演算法 ^{*}

Skip-grams

空間維度 [!]

100

篩選最低詞頻 [!]

5

參考字詞數 [!]

5

儲存更改

參數	設定值	說明與依據
演算法	SKIP-GRAMS	對低頻 ESG 專業術語的表現優於 CBOW
空間維度	100	經驗法則： < 10 萬篇之小語料採 50-100
篩選最低詞頻	5	過濾出現 < 5 次之雜訊詞（斷詞錯誤、
參考字詞數	5	預測中心詞前後各 5 個詞之上下文


任務結果

Show 10 entries

Search:

word	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18
ai	-0.110830	0.118733	-0.062084	-0.414840	-0.089973	0.469628	0.057625	0.094693	0.566499	-0.773257	0.244747	-0.864235	-0.027655	0.318372	0.135703	-0.471405	0.217868	-0.698363	0.239134
esg	-0.116282	-0.184261	-0.859917	0.038887	-0.511038	-0.457690	0.253410	0.149155	-0.289440	0.121730	0.109680	-0.577878	-0.091778	0.216413	0.281964	-0.001238	0.707051	-0.515551	0.375191
中心	0.175866	0.443723	-0.170963	-0.696652	-0.475135	0.563474	0.570527	0.032965	0.517782	-0.211427	-0.006102	-0.756185	-0.089479	-0.526168	0.188296	-0.341407	0.068327	-0.445557	0.289126
人才	0.248582	-0.247440	-0.023972	-0.107807	-0.850799	-0.281226	-0.346511	0.168225	-0.146148	-0.614007	0.588668	-0.431069	-0.400541	0.111528	0.052629	-0.648040	0.161837	-0.951693	0.333920
今年	0.321195	0.550961	-0.466967	0.372213	-0.151221	-0.007537	0.355589	0.395928	-0.133502	-0.045576	-0.054061	-0.548635	-0.321706	0.126751	0.389556	0.224433	0.152502	-0.246197	0.046787
企業	-0.022601	0.024702	-0.531725	-0.196527	-0.783590	-0.237512	0.048381	0.455300	-0.752842	0.008293	-0.179910	-0.284074	-0.016197	0.458635	-0.346214	0.324949	0.312667	-0.453592	-0.043424
使用	0.006656	0.265262	-0.083487	0.016132	-0.059919	-0.738194	0.384597	-0.187391	-0.223077	-0.008192	-0.300625	-0.205226	0.069361	-0.091245	-0.568159	0.416747	-0.218986	-0.517813	-0.143967
健康	-0.449493	0.292488	-0.922239	0.033141	0.126347	-0.411606	-0.101664	0.382230	0.193841	0.335905	-0.063742	-0.523350	-0.248871	-0.035055	0.134425	0.599857	0.030158	-0.229108	0.249067
億元	0.251440	1.081795	-0.565198	-0.154139	-0.619182	0.214001	1.193410	0.224545	0.455471	-0.405975	-0.065894	-0.047484	-0.761903	0.267872	-0.405604	-0.061847	0.310277	-0.605894	0.400301
全球	0.794247	0.066193	-0.180263	-0.130649	-0.890527	0.050057	-0.111026	0.185798	-0.375701	-0.063933	0.164559	-0.800411	0.327559	0.638636	-0.248793	0.201764	0.450375	-0.539223	0.078588

ai	-0.165	-0.414	-0.031	-0.898	-0.198	0.537	...
esg	-0.046	-0.052	-0.558	-0.125	-0.241	-0.225	...
中心	-0.384	0.162	0.037	-0.05	-0.861	0.299	...
人才	0.211	0.008	0.029	-0.239	-0.531	-0.018	...
企業	0.019	0.478	-0.723	0.02	-0.586	-0.077	...
全球	0.637	0.316	-0.197	-0.116	-0.721	-0.275	...
.....							



LDA模型視覺化

統計資訊

100

字數



5

主題數

-1.313

主題連貫性(UMass)



0.080

主題連貫性(PMI)



0.433

主題連貫性(Cv)




1783.74

混淆度




LDA Vis




主題

LDA Vis




主題

LDA Vis




主題

LDA Vis



主題




LDA Vis



主題

GUIDED LDA



模型視覺化



主題

主題

主題



主題

主題

備註：每個TOPIC內詞彙以分數高至低排序，從上到下 左到右依序。

BERTOPIC主題模型分析

分析文章數：4,325

識別主題數：5

TOP詞彙：20

256篇 5.9% TOPIC 0 – ESG 社會責任與活動 台灣、永續、提供、活動、發展、表示、企業、產業、服務、公司、透過、合作	935篇 21.6% TOPIC 1 – 科技產業與全球市場 台灣、AI、發展、市場、表示、企業、美國、投資、全球、川普、經濟	1893篇 43.8% TOPIC 2 – 企業 ESG 金融與治理 永續、企業、發展、金融、社會、公司、服務、持續、推動、ESG、創新
629篇 14.5% TOPIC 3 – 碳費減碳與氣候政策 減碳、碳費、企業、目標、環境部、費率、碳權、氣候、減量、表示、台灣	612篇 14.2% TOPIC 4 – 再生能源與電力轉型 能源、台灣、電力、綠電、再生、能源、表示、發展、產業、技術、政府、公司、全球、發電、目標、未來、合作	

10

BERT TOKENIZER 對中文的影響分析

01

字元級切割：

BERT 預設以單字元為 **TOKEN**，中文一字 ≠ 一詞（如「再生能源」被切成 **4** 個字元），導致語意嚴重碎片化。

02

詞彙表未含中文專業詞：

BERT 原始 **VOCAB** 缺乏「碳費」「盤查」「綠電」等 **ESG** 術語，模型以 **[UNK]** 或其他字元拼接替代，影響語義、品質。

03

停用詞過濾不足：

「表示」「今年」等高頻低語義詞同時出現在 **TOPIC 0、1、3、4** 的 **TOP** 詞中，顯示停用詞處理不夠完善。

04

跨語言向量偏移：

使用多語系 **BERT**（如 **MBERT**）時，中英文語意空間對齊不完美，混雜「**AI**」「**COP**」「**ESG**」等英文縮寫可能干擾主題邊界。

GuidedLDA 5主題：參數、GRI種子詞與分析邏輯

5

主題數

100

字數/
詞向量維度

-1.085

UMASS：
越接近 0 越好

0.032

PMI：詞關聯
強度

0.454

CV：語意連
貫性

2515.81

混淆度

指標解讀：**5**主題能拆出更細議題，但混淆度提高，代表模型較複雜；後續重點放在「可解釋性」而非只追求單一指標

GRI面向	對應邏輯	種子詞
E 環境	能源、排放、氣候、碳管理	碳排、溫室氣體、再生能源、用電、減碳、淨零、碳盤查、氣候、COP
S 社會	員工、職安、供應鏈、人權、生活服務	員工、薪酬、供應鏈、職安、人權、多元、健康、服務、活動
G 治理	法規、揭露、風險、公司治理與產業轉型	法規、資訊揭露、董事會、內控、風險管理、廉潔、產業、投資、管理


未使用到的種子詞

溫室氣體、碳盤查、水資源、職安、資訊揭露、內控、風險管理、廉潔

→下次可補同義詞或提高專有詞命中率

五主題結果：從 TOP 詞命名到 ESG 語

依 TOPIC 1-5 的高權重詞重新命名，將 ESG 拆成金融治理、科技轉型、政策、生活與國際政治。



歸類	Topic	
G 治理	1、2	ESG 被寫成企業治理
E 環境	3、5	分成國內碳費政策與
S 社會	4	落在生活服務、健康

命名規則：先看 TOP 詞 → 對照 GRI 邏輯 → 再確認新聞語境

結論：ESG 會依照新聞版別被重新包裝

量化比例顯示版別差異；質化解讀說明版別敘事邏輯

全球版

97.9%

E 環境 | 國際氣候政策

產經版

60.9%

G 治理 / 產業 | 企業轉型

生活版

60.1%

S 社會 | 永續服務

量化結論

- 五主題占比相對平均
- ESG 不集中在單一議題
- 版別主題差異明顯

質化結論

- 全球版：氣候與政策
- 產經版：企業與轉型
- 生活版：社會與服務

方法結論

- GuidedLDA 對齊 GRI 架構
- BERTopic 補充細分語境
- 同時看見大架構與細差異

ESG 不是單一環保新聞，而是被重新包裝成「國際氣候政策、企業產業轉型、社會永續服務」三種主要敘事

同樣叫 **ESG**，放在不同版面，講的故事就不一樣

Q&A